

## PONTIFICIA UNIVERSIDAD JAVERIANA

Maestría en Analítica para la Inteligencia de Negocios

Métodos de Analítica II

# INFORME FINAL — METODOLOGÍA CRISP-DM

## Predicción de Bajo Peso al Nacer

Clasificación Supervisada con Regresión Logística, SVM, Bagging, Random Forest y XGBoost

Bogotá, Colombia — Abril 2026

## Resumen Ejecutivo

El presente informe documenta el desarrollo de un modelo predictivo para identificar bebés en riesgo de bajo peso al nacer, utilizando la metodología CRISP-DM (Cross-Industry Standard Process for Data Mining). El análisis se realizó sobre un dataset de aproximadamente 4.25 millones de registros de nacimientos en Estados Unidos, comparando ocho modelos de clasificación supervisada.

El modelo ganador fue XGBoost con hiperparámetros optimizados mediante búsqueda en cuadrícula (GridSearchCV), alcanzando un AUC de 0.8986 y un Recall de 78.66% sobre el conjunto de test. Esto implica que el modelo detecta correctamente casi 4 de cada 5 bebés que nacerán con bajo peso, utilizando únicamente información disponible antes del nacimiento.

| Métrica clave      | Modelo ganador     | Vs. baseline             |
|--------------------|--------------------|--------------------------|
| AUC                | 0.8986             | +0.0128 sobre LR Ingenuo |
| Recall (bajo peso) | 78.66%             | +2.25pp sobre LR Ingenuo |
| Algoritmo          | XGBoost Optimizado | Gradient Boosting        |
| Dataset            | 4.25M registros    | Train 70% / Test 30%     |

## Fase 1 — Comprensión del Negocio

### 1.1 Contexto y Motivación

El bajo peso al nacer (BPN) se define por la Organización Mundial de la Salud (OMS) como un peso inferior a 2,500 gramos (equivalente a 5.5 libras) en el momento del nacimiento. Es uno de los factores de riesgo más importantes para la mortalidad y morbilidad neonatal, asociado con complicaciones respiratorias, problemas neurológicos, mayor susceptibilidad a infecciones y consecuencias a largo plazo sobre el desarrollo cognitivo y la salud metabólica del individuo.

A nivel global, el BPN afecta aproximadamente al 15% de todos los nacimientos, con variaciones significativas entre países y grupos poblacionales. En Estados Unidos, la tasa ronda el 8%, con disparidades marcadas según raza, nivel socioeconómico y acceso a atención prenatal.

La identificación temprana de embarazos en riesgo de producir un bebé con bajo peso permite a los equipos médicos intensificar el seguimiento prenatal, ajustar intervenciones nutricionales, gestionar condiciones crónicas de la madre y preparar los recursos neonatales necesarios para el parto. Un modelo predictivo preciso y explícito representa una herramienta de apoyo a la decisión clínica de alto valor.

### 1.2 Objetivo Analítico

**Objetivo principal:** desarrollar y comparar modelos de clasificación supervisada que predigan, con la mayor precisión posible, si un bebé nacerá con bajo peso utilizando únicamente información disponible antes o durante el embarazo, sin incluir datos post-nacimiento.

**Variable objetivo:** `bebes_de_bajo_peso` (binaria) — True si peso al nacer  $\leq 5.5$  libras, False en caso contrario.

### 1.3 Criterios de Éxito

Dado el contexto clínico, se priorizaron las siguientes métricas en orden de importancia:

- AUC-ROC: métrica principal para comparar modelos. Evalúa la capacidad de discriminación sin depender del umbral de clasificación.
- Recall (Sensibilidad) de la clase positiva: porcentaje de bebés de bajo peso correctamente identificados. En contexto clínico, los falsos negativos (casos reales no detectados) son más costosos que los falsos positivos.
- Precisión y F1-score: métricas secundarias para evaluar el balance entre detección y alarmas falsas.

Se definió como umbral de éxito un AUC superior a 0.85 y un Recall superior al 70% en la clase positiva.

### 1.4 Restricciones y Consideraciones Éticas

- Restricción de leakage: solo se utilizan variables disponibles antes del nacimiento. Variables como el Score Apgar (medido al minuto y a los 5 minutos post-nacimiento) fueron explícitamente excluidas.

- Equidad algorítmica: las variables de raza se incluyeron como proxies socioeconómicos y geográficos, no como factores causales. El análisis mostró que la categoría "Negro" tiene una tasa de bajo peso 5.4pp superior al promedio, lo cual refleja desigualdades sistémicas documentadas en la literatura.
- Privacidad: el dataset es de carácter público y anonimizado. No contiene identificadores personales directos.

## Fase 2 — Comprensión de los Datos

### 2.1 Descripción del Dataset

El dataset "peso\_bebes.csv" contiene registros de nacimientos en Estados Unidos, con las siguientes características generales:

| Característica      | Valor                                                            |
|---------------------|------------------------------------------------------------------|
| Total de registros  | 4,255,156 nacimientos                                            |
| Columnas originales | 32 variables                                                     |
| Periodo             | Registros de nacimientos en EE.UU. (múltiples años)              |
| Variable objetivo   | bebes_de_bajo_peso (binaria): 7.88% positivos / 92.12% negativos |
| Distribución clase  | Altamente desbalanceada — requiere estrategias de compensación   |

### 2.2 Análisis de Calidad de Datos

#### 2.2.1 Valores Duplicados

Se identificaron 388 filas duplicadas exactas (0.01% del total), verificadas sobre el dataset completo antes de cualquier eliminación de columnas. Al ser duplicados exactos en todas las columnas originales incluyendo identificadores de alta cardinalidad, se determinó que corresponden a errores de captura y fueron eliminados.

#### 2.2.2 Valores Nulos — Patrón de Missingness Estructural

El hallazgo más significativo en la calidad de datos fue la identificación de un patrón de missingness estructural: cigarette\_use, alcohol\_use y las variables de raza presentan exactamente el mismo porcentaje de nulos (~65%), lo que indica que estos campos no fueron recolectados en ciertos estados o años, no que sean datos faltantes aleatorios.

| Variable           | Nulos     | % del total | Tipo de missingness   |
|--------------------|-----------|-------------|-----------------------|
| cigarette_use      | 1,937,110 | 65.0%       | Estructural (MNAR)    |
| cigarettes_per_day | 1,937,110 | 65.0%       | Estructural (MNAR)    |
| alcohol_use        | 1,937,110 | 65.0%       | Estructural (MNAR)    |
| mother_race        | 2,912,647 | 68.4%       | Estructural (MNAR)    |
| father_race        | 2,912,647 | 68.4%       | Estructural (MNAR)    |
| weight_gain_pounds | 95,016    | 2.2%        | Informativo — Δ4.93pp |
| gestation_weeks    | 5,820     | 0.1%        | Aleatorio (MCAR)      |

Para weight\_gain\_pounds se realizó un análisis adicional que reveló una diferencia de 4.93 puntos porcentuales en la tasa de bajo peso entre registros con y sin dato (12.70% vs 7.77%), confirmando que el NaN en esta variable es informativo y debe preservarse como feature.

### 2.3 Variables del Modelo

Tras el proceso de selección y preparación, el modelo final utiliza las siguientes 30 features:

| Variable             | Tipo       | Descripción                                     | Relevancia                                 |
|----------------------|------------|-------------------------------------------------|--------------------------------------------|
| gestation_weeks      | Numérica   | Semanas de gestación                            | Alta — principal predictor clínico         |
| plurality            | Numérica   | Número de bebés (1=único, 2=gemelos...)         | Alta — gemelos nacen con menos peso        |
| weight_gain_pounds   | Numérica   | Ganancia de peso de la madre                    | Alta — NaN informativo ( $\Delta 4.93pp$ ) |
| cigarettes_per_day   | Numérica   | Cigarrillos por día durante embarazo            | Media — tabaquismo prenatal                |
| mother_age           | Numérica   | Edad de la madre                                | Media                                      |
| father_age           | Numérica   | Edad del padre                                  | Media                                      |
| is_male              | Booleana   | Sexo del bebé                                   | Media — varones tienden a ser más pesados  |
| mother_married       | Booleana   | Estado civil de la madre                        | Media — proxy socioeconómico               |
| cigarette_use        | Booleana   | Si la madre fuma                                | Media                                      |
| alcohol_use          | Booleana   | Si la madre consume alcohol                     | Baja                                       |
| mother_race          | Categorica | Raza de la madre (OHE: 6 cat + Other + Unknown) | Media — Negro +5.4pp sobre promedio        |
| father_race          | Categorica | Raza del padre (OHE: 6 cat + Other + Unknown)   | Media                                      |
| cigarette_reported   | Indicador  | Si el dato de tabaquismo fue recolectado        | Media — missingness estructural 65%        |
| alcohol_reported     | Indicador  | Si el dato de alcohol fue recolectado           | Media                                      |
| race_reported        | Indicador  | Si el dato de raza fue recolectado              | Media                                      |
| weight_gain_reported | Indicador  | Si la ganancia de peso fue recolectada          | Alta — NaN informativo                     |

## Fase 3 — Preparación de los Datos

### 3.1 Eliminación de Variables

Se eliminaron variables en dos etapas, con justificación explícita para cada una:

| Variable                   | Razón            | Justificación detallada                                                             |
|----------------------------|------------------|-------------------------------------------------------------------------------------|
| weight_pounds              | Leakage crítico  | Es la fuente directa del target. Incluirla equivale a darle la respuesta al modelo. |
| apgar_1min /<br>apgar_5min | Leakage temporal | Medidos post-nacimiento. No disponibles en el momento de predicción.                |
| month / wday               | No disponible    | Fecha de nacimiento — no se conoce antes del parto.                                 |
| Imp                        | Redundante       | Redundante con gestation_weeks. Muchos valores inválidos (99/9999).                 |
| record_weight              | No predictiva    | Variable de diseño muestral (1=completo, 2=muestra 50%). No predice peso.           |
| 13 columnas<br>constantes  | Sin varianza     | Un solo valor único en toda la columna — aportan cero información.                  |

### 3.2 Creación de la Variable Objetivo

Se definió **bebés\_de\_bajo\_peso** = (**weight\_pounds** ≤ 5.5) siguiendo el umbral de la OMS para bajo peso neonatal (< 2,500g ≈ 5.5 libras). La variable objetivo se creó antes de eliminar **weight\_pounds** para evitar perder la referencia.

Distribución en el dataset completo: 7.88% de positivos (bajo peso) vs 92.12% de negativos, representando un desbalance de clases de aproximadamente 1:11.7.

### 3.3 Ingeniería de Features

#### 3.3.1 Indicadores de Missingness

En lugar de imputar el 65-68% de nulos en las variables de tabaquismo, alcohol y raza con la moda (lo cual inventaría datos para 2.7M de registros), se crearon indicadores binarios que el modelo puede usar como features:

- cigarette\_reported: 1 si el dato de tabaquismo fue recolectado, 0 si no.
- alcohol\_reported: 1 si el dato de alcohol fue recolectado, 0 si no.
- race\_reported: 1 si el dato de raza fue recolectado, 0 si no.
- weight\_gain\_reported: 1 si la ganancia de peso fue recolectada, 0 si no (NaN informativo con Δ4.93pp).

#### 3.3.2 Imputaciones Lógicas Deterministas

- cigarettes\_per\_day = 0 cuando cigarette\_use == False: si la madre no fuma, los cigarrillos por día son cero por definición.
- drinks\_per\_week = 0 cuando alcohol\_use == False: misma lógica.

#### 3.3.3 Preparación de Variables de Raza — Criterio Dual

Las variables de raza requerían un tratamiento especial por dos razones: (1) los NaN no deben imputarse con la moda (White) porque crearía una señal falsa; (2) categorías pequeñas en frecuencia pueden tener alta señal predictiva.

Se aplicó un criterio dual para conservar categorías: una categoría se conserva si tiene frecuencia  $\geq 0.5\%$  sobre no-nulos (volumen suficiente) O si su tasa de bajo peso difiere  $\geq 4pp$  del promedio general (señal predictiva fuerte). El análisis sobre el train completo reveló que solo la categoría "Negro" supera el umbral de señal (+5.4pp), mientras que categorías como "Vietnamita" que parecían tener alta señal en muestras pequeñas (14.3% con  $n=14$ ) resultaron no significativas con datos completos (6.6% con  $n=1,362$ ).

Los NaN se convirtieron en la categoría explícita "Unknown" en lugar de imputarse, y las categorías pequeñas sin señal se agruparon en "Other\_bajo\_riesgo".

### 3.4 División Train / Test

Se realizó una división estratificada 70%/30% antes del análisis exploratorio, garantizando que la proporción de positivos (7.88%) sea idéntica en ambos conjuntos:

| Conjunto    | Registros | % Bajo peso |
|-------------|-----------|-------------|
| Train (70%) | 2,978,337 | 7.88%       |
| Test (30%)  | 1,276,431 | 7.88%       |

### 3.5 Pipeline de Preprocesamiento

Se implementó un pipeline de sklearn que garantiza que las transformaciones se aprenden únicamente sobre el conjunto de entrenamiento, evitando data leakage en la imputación y escalado. El ColumnTransformer aplica transformaciones distintas según el tipo de variable:

- Variables numéricas (10): imputación con mediana + StandardScaler.
- Variables categóricas (2 — raza): OneHotEncoder sin imputación (NaN ya convertidos a "Unknown").
- Variables booleanas (4): imputación con moda.
- Para XGBoost: se usó "passthrough" en lugar de StandardScaler, ya que los árboles son invariantes a la escala y XGBoost maneja NaN nativamente.



## Fase 4 — Modelado

### 4.1 Estrategia de Modelado

Se compararon ocho configuraciones de modelos, organizadas en un modelo baseline y seis modelos principales, más una variante optimizada del mejor modelo:

- Modelo ingenuo (baseline): Regresión Logística sin optimización de hiperparámetros.
- M1 — LR con regularización: GridSearchCV sobre L1, L2 y ElasticNet con diferentes valores de C.
- M2 — SVM Lineal: LinearSVC con calibración de probabilidades (Platt scaling).
- M3 — Bagging: 100 árboles de decisión con bootstrap, max\_depth=20.
- M4 — Random Forest: 100 árboles con selección aleatoria de features (max\_features=sqrt).
- M5 — XGBoost: Gradient Boosting con 500 árboles y scale\_pos\_weight=11.7.
- M6 — XGBoost + RFE: Eliminación Recursiva de Features sobre XGBoost (15 de 30 features).
- XGBoost Optimizado: M5 con hiperparámetros optimizados mediante GridSearchCV secuencial.

Para manejar el desbalance de clases (1:11.7), se usó class\_weight="balanced" en LR y SVM, balanced\_subsample en Random Forest, y scale\_pos\_weight=11.7 en XGBoost.

### 4.2 Consideraciones de Escalabilidad

El dataset de 2.97M registros para entrenamiento impone restricciones computacionales significativas. Se adoptaron las siguientes estrategias:

- Muestra de desarrollo (1%): durante el desarrollo del código, se usó el 1% del train (~29,800 registros) para verificar la lógica de cada modelo en segundos.
- GridSearchCV sobre 10-20% del train: para la búsqueda de hiperparámetros se usó una muestra estratificada, evitando el error de memoria que ocurre al correr el grid sobre los 2.97M completos con múltiples workers.
- n\_jobs=1 para Bagging y Random Forest: estos modelos con n\_jobs=-1 crean 16 copias del dataset en RAM simultáneamente (~16GB), causando crashes en equipos con 16GB. El modo secuencial evita este problema.
- Producción con train completo: los modelos finales se entrenaron sobre los 2.97M registros para máxima capacidad predictiva.

### 4.3 Optimización de XGBoost

Dado que XGBoost resultó ser el mejor modelo con solo 1.5 minutos de entrenamiento, se realizó una búsqueda secuencial de hiperparámetros en dos rondas:

| Ronda | Parámetros explorados                                     | Mejor valor encontrado             | Combinaciones   | AUC CV |
|-------|-----------------------------------------------------------|------------------------------------|-----------------|--------|
| 1     | n_estimators: [500, 1000, 1500]learning_rate: [0.05, 0.1] | n_estimators=500learning_rate=0.05 | 6 × 3 = 18 fits | 0.8916 |

|   |                                                   |                                |                        |        |
|---|---------------------------------------------------|--------------------------------|------------------------|--------|
| 2 | max_depth: [6, 8, 10]min_child_weight: [1, 5, 10] | max_depth=6min_child_weight=10 | $9 \times 3 = 27$ fits | 0.8976 |
|---|---------------------------------------------------|--------------------------------|------------------------|--------|

El parámetro min\_child\_weight=10 indica que un nodo solo se divide si tiene al menos 10 casos — evita splits sobre ruido en la clase minoritaria (7.88%). El learning\_rate=0.05 con solo 500 árboles supera a configuraciones con más árboles y tasa más alta, confirmando que un aprendizaje más lento y preciso es óptimo para este problema.

## Fase 5 — Evaluación

### 5.1 Resultados Comparativos

La siguiente tabla presenta los resultados sobre el conjunto de test completo (1,276,431 registros), evaluados con el umbral de decisión de 0.5 (excepto SVM, evaluado con umbral 0.3 para compensar la conservaduridad del calibrador Platt):

| Modelo             | AUC    | Recall | Precisi<br>on | F1 Bajo<br>Peso | Umbral | Nota             |
|--------------------|--------|--------|---------------|-----------------|--------|------------------|
| XGBoost Optimizado | 0.8986 | 0.7866 | 0.34          | 0.79            | 0.48   | ★<br>Ganado<br>r |
| Random Forest      | 0.8893 | 0.7389 | 0.44          | 0.74            | 0.55   |                  |
| XGBoost + RFE      | 0.8953 | 0.7811 | 0.35          | 0.78            | 0.48   |                  |
| XGBoost (base)     | 0.8958 | 0.7804 | 0.35          | 0.78            | 0.48   |                  |
| LR Ingenuo         | 0.8858 | 0.7641 | 0.35          | 0.76            | 0.49   | Baselin<br>e     |
| LR Regularizada    | 0.8858 | 0.7640 | 0.35          | 0.76            | 0.49   |                  |
| SVM Lineal         | 0.8857 | 0.5073 | 0.63          | 0.51            | 0.56   |                  |
| Bagging            | 0.8788 | 0.6910 | 0.38          | 0.69            | 0.50   |                  |

### 5.2 Análisis de Resultados

#### 5.2.1 XGBoost como Modelo Ganador

XGBoost Optimizado alcanzó el mejor AUC (0.8986) y el mejor Recall (78.66%), superando al baseline en 0.0128 puntos de AUC. Esta diferencia es estadísticamente significativa con 1.27M de registros de test. Los factores que explican su superioridad son: (1) capacidad de capturar relaciones no lineales entre gestation\_weeks, plurality y el peso; (2) manejo nativo de NaN sin necesidad de imputación; y (3) corrección iterativa de errores mediante boosting.

#### 5.2.2 Modelos Lineales Competitivos

La Regresión Logística Ingenua (AUC 0.8858) es notablemente competitiva respecto a XGBoost, con solo 0.0128 de diferencia. Esto sugiere que el problema tiene una estructura predominantemente lineal — variables como gestation\_weeks y plurality tienen relaciones casi lineales con el riesgo de bajo peso. La regularización (L1, L2, ElasticNet) no aportó mejora sobre el modelo sin regularizar, lo cual es esperado con 2.97M de datos: la masa estadística actúa como regulador natural.

#### 5.2.3 RFE No Mejoró con Datos Completos

XGBoost + RFE (AUC 0.8953) quedó por debajo de XGBoost sin RFE (AUC 0.8958). Con 3M de registros, features que parecían ruido en la muestra de desarrollo (29k registros) ahora aportan señal marginal suficiente para el modelo. Esto es un hallazgo metodológico importante: la eliminación de features es más beneficiosa en datasets pequeños que en datasets grandes.

#### 5.2.4 Bagging y Random Forest

Random Forest (AUC 0.8893) superó a Bagging (AUC 0.8788), confirmando que la decorrelación de árboles mediante selección aleatoria de features (`max_features=sqrt`) aporta beneficio sobre el Bagging puro. Ambos modelos quedaron por debajo de los modelos lineales con el 1% de datos de desarrollo, pero escalaron significativamente con el train completo, validando la importancia de ejecutar los modelos basados en árboles con datos completos.

5.2.5 SVM y el Problema del Umbral

El SVM Lineal obtuvo el tercer mejor AUC (0.8857) pero el peor Recall (50.73%) con umbral estándar. Esto se debe a que la calibración Platt scaling no preserva perfectamente el efecto de `class_weight="balanced"`, haciendo al modelo más conservador. Al bajar el umbral a 0.3, el Recall mejoró a 50.73%, pero sigue siendo inferior a los demás modelos. El AUC competitivo confirma que el SVM tiene buen poder de discriminación, pero su calibración de probabilidades es subóptima para este problema.

5.3 Feature Importance — XGBoost Optimizado

El análisis de importancia de variables (basado en ganancia de información) reveló la siguiente jerarquía:

- `gestation_weeks`: la variable más importante con amplia diferencia. Las semanas de gestación son el predictor dominante del peso al nacer desde una perspectiva clínica.
- `plurality`: gestaciones múltiples (gemelos, trillizos) tienen peso significativamente menor.
- `weight_gain_pounds`: la ganancia de peso de la madre durante el embarazo es el tercer predictor más importante.
- `cigarettes_per_day`: el tabaquismo prenatal tiene un efecto negativo documentado sobre el peso fetal.
- `race_reported` y variables de raza del padre: capturan patrones socioeconómicos y geográficos asociados al riesgo.
- `is_male` y `mother_married`: sexo del bebé y estado civil como proxies del contexto del embarazo.

El análisis SHAP (SHapley Additive exPlanations) confirmó estas jerarquías y mostró que semanas de gestación bajas y embarazos múltiples tienen el mayor impacto positivo sobre la predicción de bajo peso, mientras que mayor ganancia de peso de la madre y ser del sexo masculino reducen el riesgo predicho.

5.4 Cumplimiento de Criterios de Éxito

| Criterio              | Meta   | Resultado  | Estado     |
|-----------------------|--------|------------|------------|
| AUC-ROC               | > 0.85 | 0.8986     | CUMPLIDO ✓ |
| Recall clase positiva | > 70%  | 78.66%     | CUMPLIDO ✓ |
| Modelo sin leakage    | 100%   | Verificado | CUMPLIDO ✓ |

## Fase 6 — Despliegue y Recomendaciones

### 6.1 Modelo Recomendado para Producción

Se recomienda implementar XGBoost con los siguientes hiperparámetros finales:

| Hiperparámetro   | Valor                |
|------------------|----------------------|
| n_estimators     | 500                  |
| learning_rate    | 0.05                 |
| max_depth        | 6                    |
| min_child_weight | 10                   |
| subsample        | 0.8                  |
| colsample_bytree | 0.8                  |
| scale_pos_weight | 11.7 (ratio neg/pos) |

### 6.2 Umbral de Decisión

En contexto clínico, el umbral de 0.5 puede ajustarse según la tolerancia al riesgo. Con umbral 0.5: Recall=78.66%, Precisión=34%. En un escenario donde se priorice detectar el máximo de casos (minimizar falsos negativos), se recomienda bajar el umbral a 0.3-0.4, aumentando el Recall a expensas de más alarmas falsas. Esta decisión debe tomarse en coordinación con los equipos médicos.

### 6.3 Limitaciones del Modelo

- Datos históricos de EE.UU.: el modelo fue entrenado con datos de nacimientos de EE.UU. Su aplicabilidad a otras poblaciones requiere validación adicional.
- Missingness estructural: el 65% de datos faltantes en tabaquismo y alcohol limita la señal de estas variables. En contextos con mejor recolección de datos, estas variables podrían aportar más.
- No captura interacciones complejas con condiciones médicas: diabetes gestacional, preeclampsia y otras condiciones que no están en el dataset pero son factores de riesgo conocidos.
- Recall del 78.66%: el modelo no detecta el 21.34% de los casos reales. En producción debe complementarse con evaluación clínica.

### 6.4 Próximos Pasos Recomendados

- Validación temporal: reentrenar el modelo con datos de los últimos 2-3 años disponibles y evaluar la estabilidad de las métricas a lo largo del tiempo.
- Análisis de equidad: evaluar el desempeño del modelo desagregado por raza y nivel socioeconómico para identificar posibles sesgos diferenciales.
- Integración de variables clínicas adicionales: si el sistema de salud dispone de datos sobre condiciones médicas de la madre, su incorporación podría mejorar significativamente el AUC.
- Monitoreo en producción: implementar alertas sobre deriva del modelo (data drift) al detectar cambios en la distribución de las variables de entrada.



## Conclusiones

Este proyecto demostró que es posible predecir con alta precisión el riesgo de bajo peso al nacer utilizando información disponible antes del parto, con un AUC de 0.8986 y un Recall del 78.66% en el modelo XGBoost optimizado.

Los hallazgos metodológicos más relevantes del proceso CRISP-DM fueron:

- El missingness estructural del 65% en variables clave no debe imputarse con moda — los indicadores binarios de missingness capturan mejor el patrón real.
- El análisis de tasas de bajo peso por categoría de raza sobre el train completo fue fundamental para evitar decisiones erróneas basadas en muestras pequeñas.
- Con 2.97M de registros, la regularización no aportó mejora sobre el modelo sin regularizar — la masa de datos actúa como regulador natural.
- La eliminación de features (RFE) es más beneficiosa en datasets pequeños; con datos completos, XGBoost sin RFE superó a XGBoost con RFE.
- El ajuste de hiperparámetros de XGBoost mediante búsqueda secuencial en dos rondas aportó +0.0028 de AUC sobre la configuración base, justificando el proceso de optimización.

Desde la perspectiva de negocio, el modelo representa una herramienta de alto valor para sistemas de salud que buscan identificar tempranamente embarazos en riesgo, permitiendo intervenciones preventivas focalizadas que pueden reducir la mortalidad neonatal y los costos asociados a la atención de bebés de bajo peso.